

Proyecto del Parcial II

Autores: Sara Elizabeth Maya León, Isaac Cesar Mendoza Malavé

Tema: AGENTE CONVERSACIONAL PARA ADMISIÓN Y
NIVELACIÓN DE LA UG

Facultad de Ciencias Matemáticas y Físicas, Universidad de
Guayaquil

CDDEIA-ELNO-4-2: Ciencia de Datos e Inteligencia Artificial

Ing. Ángel Cuenca Ortega

10 de julio de 2026

Introducción

Cada periodo de admisión y nivelación de la Universidad de Guayaquil (UG) genera un alto volumen de consultas repetitivas por parte de los aspirantes: requisitos de inscripción, fechas de registro y matrícula, creación de cuentas, aprobación de asignaturas, cupos y aceptación de carreras. Gran parte de esta información se encuentra dispersa entre el portal oficial de admisión, la página de nivelación y los canales de redes sociales de la institución, lo que dificulta su consulta ágil por parte del estudiante.

Este proyecto aborda ese problema mediante un agente conversacional (chatbot) que responde en español preguntas frecuentes sobre admisión y nivelación de la UG, aplicando exclusivamente técnicas clásicas de Procesamiento de Lenguaje Natural (PLN): representación TF-IDF, similitud coseno para la detección de intención y reglas/expresiones regulares para la extracción de entidades. El agente no incluye modelos de deep learning ni embeddings preentrenados.

1. Diseño de intenciones y entidades

Se definieron 21 intenciones (intents), cada una asociada a un conjunto de utterances (frases de usuario, incluyendo variantes con errores tipográficos y coloquialismos) y a una respuesta predefinida. Las intenciones y sus respuestas se almacenan en data/intents.json, separadas del código fuente, de modo que ampliar o corregir el dominio no requiere modificar la lógica del motor de PLN. Cada intención referencia su fuente oficial de origen, tal como exige el enunciado:

Categoría	Intenciones (tag)	Fuente
Conversacional	saludo, despedida, agradecimiento	Interacción genérica
Requisitos y cuenta	preguntar_requisitos_admision, explicar_creacion_cuenta, recuperar_cuenta, problemas_portal	Portal Oficial de Admisión UG / Redes sociales
Fechas y proceso	consultar_fechas_nivelacion, consultar_fechas_registro, consultar_cupos, aceptacion_carrera, cambio_carrera	Portal Oficial de Admisión UG / Reglamento de Admisión
Resultados y costos	consultar_resultados, consultar_costos, consultar_documentos, consultar_carreras	Portal Oficial de Admisión UG / Reglamento de Admisión
Nivelación académica	consultar_aprobacion_asignaturas, consultar_asistencia	Página de Nivelación UG
Contacto y general	consultar_canales_contacto, consulta_general_admision, fallback	Redes sociales de Admisión / N-A

Para la extracción de entidades se implementaron reglas y expresiones regulares sobre cuatro tipos: FECHA (formatos numéricos y textuales, p. ej. “10 de julio de 2026”); CÉDULA (secuencias de 10 dígitos validadas además contra el algoritmo oficial de módulo 10 del Registro Civil ecuatoriano, para distinguir una cédula real de cualquier número de 10 dígitos); CARRERA (lista curada de carreras de la UG, ordenada de más específica a más genérica para evitar que “medicina veterinaria” se resuelva como “medicina”); y TERMINO_DOMINIO (expresiones fijas del proceso, como “cupos aceptados” o “curso de nivelación”). La extracción se ejecuta sobre el texto original del usuario, sin stemming, porque este destruiría dígitos y tildes relevantes.

2. Arquitectura del agente

El flujo de una consulta atraviesa cuatro etapas secuenciales:

- Preprocesamiento: conversión a minúsculas, eliminación de tildes y puntuación, tokenización, eliminación de stopwords en español y stemming (SnowballStemmer de NLTK).
- Representación TF-IDF híbrida: se combinan dos vectorizadores en paralelo — uno por palabras (uni y bigramas, sobre el texto preprocesado) y otro por n-gramas de caracteres de 3 a 5 (sobre el texto solo limpiado, sin stemming). Ambas matrices dispersas se ponderan (0.7 palabras / 0.3 caracteres) y se concatenan horizontalmente antes de calcular similitud.
- Detección de intención: similitud coseno entre el vector de la consulta y la matriz TF-IDF de todas las utterances de entrenamiento; se selecciona la intención de mayor similitud.
- Umbral de confianza y fallback: si la similitud máxima es menor a 0.25 , el agente responde con un mensaje de fallback en vez de forzar una intención poco confiable. Todo el flujo de detección está envuelto en un bloque try/except, de modo que cualquier entrada problemática degrada de forma segura a fallback en lugar de interrumpir el proceso.

El agente puede ejecutarse localmente mediante una interfaz de consola (src/chatbot.py) o una interfaz web (src/app.py, con Flask), que incluye el logo institucional de la UG como marca de agua en el área del chat. El motor de PLN se instancia una sola vez al arrancar el proceso, de modo que el ajuste de los vectorizadores TF-IDF no se repite en cada consulta.

3. Justificación de las decisiones tomadas

Se seleccionó TF-IDF sobre una bolsa de palabras simple porque el factor IDF reduce el peso de términos hiperfrecuentes en el corpus (como “admisión” o “nivelación”) para resaltar las palabras que realmente distinguen una intención de otra, aplicando además un preprocesamiento con stemming para agrupar variantes morfológicas (como “requisito” y “requisitos”) bajo una misma raíz y evitar dimensiones redundantes en el vocabulario. Para medir la cercanía entre textos se prefirió la similitud coseno frente a la distancia euclidiana, ya que el coseno normaliza la longitud de los vectores, permitiendo que una consulta corta y una frase larga sean “cercanas” si comparten palabras clave. Además, para mitigar los errores tipográficos comunes (“nivelasion”, “amision”), se agregó un canal híbrido de n-gramas de caracteres que tolera estas variaciones sin tratar los errores como tokens fuera de vocabulario. El sistema opera bajo un umbral de confianza de 0.25 , elegido mediante un barrido empírico en src/evaluate.py que equilibra la precisión al minimizar el fallback en consultas cortas o con errores severos, aceptando un único falso positivo límite detectado a partir de 0.45 . Finalmente, el diseño mantiene una estricta separación de datos y lógica, alojando las intenciones, frases y respuestas en un archivo JSON independiente, lo que permite ampliar o corregir el dominio sin alterar el código principal en nlp_engine.py.

4. Resultados de la evaluación

Se construyó un set de 50 consultas de prueba etiquetadas (data/test_queries.csv), incluyendo variaciones lingüísticas, errores tipográficos, saludos informales (“holi”, “hi”, “hello”) y consultas ambiguas o fuera de dominio. Con el umbral de producción (0.25) se obtuvo:

Umbral de confianza	Accuracy	F1-macro	Observación
0.20 – 0.40	0.980	0.975	1 falso positivo fuera de dominio
0.25 (producción)	0.980	0.975	Prioriza responder consultas de confianza moderada
0.45 – 0.50	1.000	1.000	El falso positivo cae a fallback, pero sube el fallback en casos válidos

Limitaciones observadas

- El canal de n-gramas de caracteres, que da tolerancia a errores tipográficos, también puede generar falsos positivos cuando una consulta fuera de dominio comparte subcadenas cortas con utterances de entrenamiento.
- El set de prueba (50 consultas) es reducido frente al universo real de formas en que un estudiante puede formular una pregunta; un umbral óptimo en este set podría no generalizar igual ante un volumen mayor de tráfico real.
- La validación de cédula verifica estructura y dígito verificador, pero no consulta un padrón real: no puede confirmar que la cédula pertenezca efectivamente a un aspirante registrado.
- Intenciones semánticamente cercanas (p. ej. agradecimiento vs. despedida) pueden confundirse en frases mixtas, porque TF-IDF captura coincidencia léxica/ortográfica y no intención pragmática.

5. Conclusión

El agente conversacional desarrollado cumple el objetivo planteado: identifica la intención del usuario y devuelve respuestas pertinentes a preguntas frecuentes de admisión y nivelación de la UG, utilizando exclusivamente técnicas clásicas de PLN (TF-IDF y similitud coseno), sin recurrir a deep learning ni modelos preentrenados. La combinación de un canal léxico y uno de caracteres demostró ser eficaz para tolerar errores tipográficos comunes en consultas reales, y el mecanismo de umbral y fallback permite manejar de forma controlada las consultas no reconocidas.

Como trabajo futuro, el propio enunciado habilita como extensión opcional el uso de embeddings semánticos o modelos preentrenados, que podrían mejorar la generalización ante formulaciones no vistas en el corpus de entrenamiento. Asimismo, ampliar el set de prueba y el corpus de utterances por intención robustecería tanto la evaluación como la cobertura del agente ante el uso real por parte de los aspirantes.

6. Repositorio de código

El código fuente completo, la carpeta data/ con las intenciones y el archivo README.md con instrucciones de ejecución se encuentran en:

github.com/RyDeRDaNesS/AgenteConversacional-para-Admision-y-Nivelacion-de-la-UG